APRENDIZAJE NO SUPERVISADO — K-MEANS CLUSTERING APLICADO AL SISTEMA DE RUTAS TRANSMILENIO BOGOTÁ

JULIANA ESTHER NARANJO CAMACHO

CORPORACION UNVERSITARIA IBEROAMERICANA

FACULTAD DE INGENIERIA

ING. SANDRA BAUTISTA

BOGOTÁ 10 OCTUBRE 2026

1. Introducción

El presente documento describe el conjunto de datos utilizado para el desarrollo del modelo de aprendizaje no supervisado aplicado al Sistema de Transporte Masivo TransMilenio de Bogotá D.C. A diferencia del aprendizaje supervisado (Actividad anterior), en esta actividad no se emplean etiquetas de clase predefinidas; en cambio, el algoritmo K-Means descubre de manera autónoma los agrupamientos naturales presentes en los datos, siguiendo los fundamentos del Capítulo 16 de Palma Méndez (2008).

2. Fuente de Datos

Dado que TransMilenio S.A. no publica microdatos de trayectos individuales con el nivel de granularidad requerido para el clustering de viajes, se construyó un dataset sintético con base en:

- La topología real de la red (4 troncales, 36 estaciones) definida en la actividad A* anterior.
- Las velocidades comerciales promedio por troncal reportadas por TransMilenio S.A. (2023): Caracas 28 km/h, Américas 30 km/h, Calle 80 32 km/h, Suba 35 km/h.
- Los factores de demanda horaria del estudio de movilidad del DANE (2021): hora pico mañana/tarde reduce la velocidad efectiva al 70–72 % de la base.
- El tiempo fijo de transbordo de 5 minutos establecido en la Resolución 652 de 2022 de TransMilenio S.A.

3. Estructura del Dataset

El archivo dataset_clustering_transmilenio.csv contiene 484 registros y 12 variables. A continuación, se describe cada variable:

Variable	Tipo	Rango / Valores	Descripción
estacion_origen	Texto	36 opciones	Nombre de la estación de partida
estacion_destino	Texto	36 opciones	Nombre de la estación de llegada
troncal_origen	Texto	4 troncales	Troncal de la estación de origen

troncal_destino	Texto	4 troncales	Troncal de la estación de destino
troncal_origen_cod	Entero	0 – 3	Troncal origen codificada numéricamente
troncal_destino_cod	Entero	0 – 3	Troncal destino codificada numéricamente
hora_periodo	Entero	0 – 5	0=Madrugada, 1=Mañana pico, 2=Mañana, 3=Tarde, 4=Tarde pico, 5=Noche
dia_tipo	Entero	0 – 2	0=Hábil, 1=Sábado, 2=Festivo
num_estaciones	Entero	1 – 20	Número de estaciones en el trayecto
num_transbordos	Entero	0 – 1	Transbordos requeridos en la ruta
distancia_km	Decimal	1.5 – 35.0 km	Distancia aproximada del recorrido
tiempo_minutos	Decimal	3.0 – 101.3 min	Tiempo total estimado del viaje

4. Estadísticas Descriptivas

Las siguientes estadísticas resumen la distribución de las variables numéricas más relevantes en el dataset:

Variable	Media	Desv. Est.	Mínimo	Máximo
tiempo_minutos	40.90	20.81	5.60	101.30
num_estaciones	10.38	4.72	1.00	20.00
distancia_km	17.55	8.95	1.51	35.00
num_transbordos	0.77	0.42	0.00	1.00
hora_periodo	2.56	1.71	0.00	5.00

5. Diferencia con el Dataset Supervisado

El dataset de clustering difiere del utilizado en la actividad de árbol de decisión en dos aspectos clave:

- No contiene la variable objetivo 'categoria_ruta' — el modelo debe descubrir los grupos por sí solo.
- Incluye las variables 'tiempo_minutos' y 'distancia_km' como features adicionales, enriqueciendo el espacio de características para el clustering.
- Cuenta con 484 registros (frente a 403) al ampliar el tamaño muestral para mayor representatividad.

7. Referencias

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 16: Técnicas de agrupamiento.

TransMilenio S.A. (2023). Informe de operación y estadísticas del sistema. Bogotá.

DANE. (2021). Encuesta de movilidad urbana — Bogotá D.C. Departamento Administrativo Nacional de Estadística.

Resolución 652 (2022). Reglamentación de transbordos y tiempos de espera. TransMilenio S.A.