PRUEBAS DEL MODELO K-MEANS

APRENDIZAJE NO SUPERVISADO — CLUSTERING DE VIAJES

JULIANA ESTHER NARANJO CAMACHO

CORPORACION UNVERSITARIA IBEROAMERICANA

FACULTAD DE INGENIERIA

ING. SANDRA BAUTISTA

BOGOTÁ 10 OCTUBRE 2026

1. Descripción del Modelo

Se implementó el algoritmo K-Means con inicialización K-Means++ para agrupar los viajes de TransMilenio en clusters de comportamiento similar. El algoritmo K-Means minimiza la suma de distancias cuadráticas intra-cluster (WCSS), asignando cada registro al centroide más cercano e iterando hasta convergencia (Palma Méndez, 2008, p. 398).

2. Parámetros del Modelo

Parámetro	Valor
Algoritmo	K-Means (Lloyd's algorithm)
Inicialización	K-Means++ (Arthur & Vassilvitskii, 2007)
K óptimo	2 (seleccionado por mayor Silhouette Score)
n_init	20 repeticiones con distinta semilla
max_iter	500 iteraciones máximas
Normalización	StandardScaler (media=0, desv. est.=1)
Features utilizadas	8 variables numéricas del dataset
random_state	42 (reproducibilidad)
Criterio K óptimo	Método del Codo + Coeficiente de Silhouette

3. Métricas de Evaluación

El aprendizaje no supervisado no dispone de etiquetas para calcular exactitud. En cambio se usan métricas internas de cohesión y separación:

Métrica	Valor	Interpretación
Inercia (WCSS)	2 751.01	Suma de distancias cuadráticas intra-cluster
Silhouette Score	0.2502	Cohesión moderada; valores cercanos a 1 son ideales
K óptimo	2	Mayor Silhouette en todo el rango K=2..8
Varianza PCA (2D)	55.3 %	Proporción explicada en la proyección 2D
Iteraciones (K=2)	11	Convergencia rápida con K-Means++
Cluster 0 — Viaje Largo	275 (56.8 %)	Tiempo medio: 55 min | 14 estaciones
Cluster 1 — Viaje Corto	209 (43.2 %)	Tiempo medio: 22 min | 6 estaciones

4. Casos de Prueba

Se seleccionaron 5 viajes representativos para verificar la coherencia de las asignaciones realizadas por el modelo:

Origen	Destino	Hora	Estac.	Tiempo (min)	Cluster
Portal Norte	Calle 72	Mañana pico	6	14.2	1 — Corto ✓
Portal Norte	Portal Sur	Mañana pico	15	55.0	0 — Largo ✓
Portal Americas	Av Jimenez	Tarde	8	24.5	1 — Corto ✓
Portal 80	Portal Sur	Tarde pico	17	67.3	0 — Largo

						✓
Portal Suba	Suba Calle 100	Noche	2	8.1	1 — Corto	✓

Los 5 casos de prueba fueron asignados correctamente al cluster esperado, confirmando que el modelo captura la distinción entre viajes cortos y largos en función del tiempo de viaje y el número de estaciones recorridas.

5. Análisis de Resultados

El modelo K-Means identificó 2 grupos naturales en los viajes de TransMilenio:

- Cluster 0 — Viaje Largo: agrupa trayectos con tiempo medio de 55 minutos, 14 estaciones y 24 km. Corresponde principalmente a viajes inter-troncales de largo recorrido.
- Cluster 1 — Viaje Corto: agrupa trayectos con tiempo medio de 22 minutos, 6 estaciones y 10 km. Corresponde a desplazamientos cortos dentro de una misma troncal.
- La proyección PCA con 55.3 % de varianza explicada muestra separación visual entre clusters, aunque con cierto solapamiento en la zona de viajes medios (25–40 min), lo que explica el Silhouette moderado de 0.25.
- La variable tiempo_minutos es el factor dominante de separación entre clusters, confirmado por los centroides y el gráfico radar.

6. Comparación con Aprendizaje Supervisado

En la actividad anterior el árbol de decisión clasificó los viajes en 3 categorías (Rápida, Media, Larga) con una exactitud del 85.95 %. El clustering K-Means, sin conocer las

etiquetas, descubrió 2 grupos naturales. Esta diferencia ilustra la distinción fundamental entre ambos paradigmas:

- Supervisado: aprende fronteras predefinidas por el experto (3 categorías).
- No supervisado: descubre la estructura inherente de los datos (2 grupos naturales).
- El solapamiento entre viajes 'Rápidos' y 'Medios' puede explicar por qué el algoritmo los fusiona en un único grupo 'Corto'.

7. Conclusiones

El modelo K-Means logró descubrir agrupaciones coherentes en los viajes de TransMilenio sin necesidad de etiquetas previas. Los clusters encontrados tienen interpretación operativa clara (viajes cortos vs. largos) y son consistentes con el conocimiento del dominio. El análisis del método del codo y el coeficiente de Silhouette permitieron determinar K=2 como el número óptimo de grupos, en línea con los principios de las técnicas de agrupamiento descritos por Palma Méndez (2008, Cap. 16).

8. Referencia

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 16: Técnicas de agrupamiento, pp. 389–415.